

HPRC A/B 双批次 GFA 生成与 W/S 重合度报告

生成时间：2026-09-13


实验目录： /Users/zizibei/Desktop/pwj/minigraph-catus

对比目录： /Users/zizibei/Desktop/pwj/minigraph-catus/results/match

1. 结论摘要

1. A 批、B 批和整合批次的 Cactus 运行均成功结束，三者都没有 `WARNING` 文件，clipping 统计显示输入序列丢失为 `0 bp`。
2. 12 条样本单倍型在“单独 GFA 的 W”和“整合 GFA 的同名 W”之间，长度均为 5,000,000 bp，**W 碱基一致率为 100%**。
3. 将单独图的每个 S 节点区间投影到整合图 W 坐标后，**S mosaic identity 为 100%**。也就是说，即使单独图的一个 S 节点在整合图中被拆成多个 S 节点，其拼接序列仍完全保留。
4. S 节点边界并未一一对应。平均边界 Jaccard 为 72.63%，边界 F1 为 84.14%。
5. 精确 1:1 S 节点区间平均占路径的 60.99%；约 36.05% 的 A 批 S 碱基跨多个整合 S 节点，B 批约 39.04%。
6. 按 S 节点序列多重集计算，平均 Jaccard bp 为 43.92%；单独图 S 节点序列在整合图中直接找到的比例平均约 61.03%。
7. 因此，“W 序列区间一致性”达到 100%，但“S 节点编号、边界和 1:1 节点结构”并不是 100% 相同。两者是不同的比较层次。

1.1 先看这张图：应该怎样理解结果



可以把每个样本的 W 想象成一条完整读出的 DNA 句子，把 S 节点想象成拼出这条句子的积木：

- **W sequence**：整条 DNA 句子是否相同；

- **S mosaic**: 句子被重新切成积木后, 重新拼起来是否仍然相同;
- **S boundary F1**: 两条句子在哪些位置使用了相同的“积木边界”;
- **Exact 1:1 S**: 某个单独图的积木是否恰好等于整合图中的一个积木;
- **S multiset Jaccard**: 两块图使用的积木序列集合到底有多少相同。

这张图最重要的读法是:

1. 前两根柱子的 W sequence 和 S mosaic 都是 100%;
2. 第三根边界 F1 约 84%, 说明积木的分界位置只有一部分相同;
3. 第四根精确 1:1 S 只有约 60%, 说明同一段序列在整合图中经常被切成不同数量的 S;
4. 第五根 S multiset Jaccard 只有约 43%, 说明节点集合/切分方式明显不同;
5. 但这些都不矛盾, 因为“积木的编号与切法不同”不等于“DNA 句子内容不同”。

1.2 为什么不能直接比较 node ID

三次 Cactus 运行是三个独立的建图过程:

- A 批运行中的 node 1;
- B 批运行中的 node 1;
- ALL 运行中的 node 1;

它们只是各次运行内部临时分配的编号, 三者没有约定对应关系。即使两条路径包含完全相同的 DNA, 节点也可能被重新编号、拆分、合并或改变方向。

因此本 Java 程序只在读取 W 时使用 node ID 去查找 S 序列; 真正参与匹配的是:

- W 重建后的完整碱基序列;
- 每个 S 节点的规范化 DNA 序列 SHA-256;
- 沿 W 累积得到的路径坐标和边界位置。

程序输出中还明确加入了:

```
node_id_comparison_used = false
w_mapping_mode = exact_forward
```

1.3 本结果“说明了”和“潜在说明了”什么

直接说明:

- A/B 单独图的 W 与 ALL 整合图中的同名 W 序列完全一致;
- 单独图 S 节点的序列内容没有丢失, 只是切分方式发生了变化;
- 联合建图会因更多样本参与而形成更密集、更细的 S 节点。

潜在说明:

- 评价 GFA 合并工具时, 不能简单要求 node ID 或 S 节点边界完全一致;

- 更合理的基础标准应是“W 序列是否一致”和“S 序列拼接后的内容是否一致”；
- 如果合并工具只按 node ID 拼接、忽略 node 序列和 W 的语义，就可能把看似相同但实际不对应的节点错误合并；
- 本实验当前数据支持的方向是：W 和 S mosaic 都达到 100%，说明序列层面具备做 99% 区间一致性验证的基础，但不能据此声称 S 节点切分也 100% 一致。

2. 实验设计

- 参考：T2T-CHM13v2 chr20, NCBI accession `NC_060944.1`。
- 区域：`chr20:10,000,001-15,000,000`，长度 5,000,000 bp。
- A 批：HPRC V1 三个样本。
- B 批：HPRC Year 2 / R3 test-set 三个样本。
- 每个样本使用两条单倍型。
- `batch_a`：CHM13v2 + A 批 6 条样本 W。
- `batch_b`：CHM13v2 + B 批 6 条样本 W。
- `all`：CHM13v2 + A/B 共 12 条样本 W，作为联合建图真值。
- 输出使用 full graph，设置 `--clip 0 --filter 0`，避免裁剪或频率过滤污染合并对比。

3. 样本选择与坐标修正

HPRC V1 原始 Year1 FASTA 中的 chr20 序列可能是未定位 WGS contig，直接用 accession 自身相同数字坐标截取会出现坐标不同源的问题。正式运行使用同一 V1 样本、同一单倍型的 NCBI f2 chr20 染色体级 accession 进行 5 Mb 区间提取。原始 accession 和最终坐标 accession 均保留在 `config/samples.tsv`。

A 批

sample	haplotype	数据来源	V1 raw contig	NCBI chr20 accession
HG00438	1	HPRC V1 / CHS	JAHBCB010000012	CM089183.1
HG00438	2	HPRC V1 / CHS	JAHBCA010000014	CM089201.1
HG01109	1	HPRC V1 / PUR	JAHEPA010000013	CM092096.1
HG01109	2	HPRC V1 / PUR	JAHEOZ010000021	CM092084.1
HG02486	1	HPRC V1 / ACB	JAGYVM010000013	CM088204.1
HG02486	2	HPRC V1 / ACB	JAGYVL010000027	CM088229.1

B 批

sample	haplotype	数据来源	NCBI chr20 accession
HG00642	1	HPRC Year 2 / R3 test-set	CM086616.1
HG00642	2	HPRC Year 2 / R3 test-set	CM086632.1
HG01884	1	HPRC Year 2 / R3 test-set	CM086415.1
HG01884	2	HPRC Year 2 / R3 test-set	CM086431.1
HG02602	1	HPRC Year 2 / R3 test-set	CM099696.1
HG02602	2	HPRC Year 2 / R3 test-set	CM099710.1

样本表: [config/samples.tsv](#)

V1 映射表: [data/manifests/hprc-v1-chr20-map.tsv](#)

4. 数据处理脚本

4.1 区间下载与抽取

脚本:

```
scripts/materialize_inputs.py
```

实际执行:

```
python3 -B /Users/zizibei/Desktop/pwj/minigraph-catus/scripts/materialize_inputs.py --jobs 2
```

处理内容:

1. 使用 `config/samples.tsv` 的 `ncbi_accession` 调用 NCBI `efetch`;
2. 设置 `seq_start=10000001&seq_stop=15000000`;
3. 对每条序列校验输出长度必须等于 5,000,000 bp;
4. 统一把输出 contig 头改写为 `>chr20`;
5. 输出到 `data/regions/chr20_10000001_15000000/`;
6. 保留每条输入的 source assembly URL、raw contig 和长度校验信息。

4.2 生成 Cactus seqfile

脚本:

```
scripts/build_seqfiles.py
```

实际执行:

```
python3 -B /Users/zizibei/Desktop/pwj/minigraph-catus/scripts/build_seqfiles.py
```

生成：

```
results/inputs/batch_a.seqfile  
results/inputs/batch_b.seqfile  
results/inputs/all.seqfile
```

A 批 7 条序列，B 批 7 条序列，ALL 批次 13 条序列。

5. Minigraph-Cactus 运行环境与命令

- Cactus: v3.3.0
- Cactus commit: df9bfd3ce2cb21f257cf3265701e1564813a5565
- Toil: 9.5.0
- 系统: Linux x86_64 VM
- CPU/内存上限: 6 cores / 20 GiB
- MAP_CORES=2
- CONS_CORES=5
- CONS_MEMORY=12G
- INDEX_CORES=5
- INDEX_MEMORY=6G

运行脚本：

```
scripts/run_cactus.sh
```

实际命令模板：

```
cactus-pangenome <jobstore> <seqfile> \  
  --outDir results/<name> --outName <name> \  
  --reference CHM13v2 --refContigs chr20 \  
  --gfa full --gbz full \  
  --clip 0 --filter 0 \  
  --mgCores 6 --mgMemory 4G \  
  --mapCores 2 --consCores 5 --consMemory 12G \  
  --indexCores 5 --indexMemory 6G \  
  --maxCores 6 --maxMemory 20G \  
  --binariesMode local
```

实际分别运行：

```
./scripts/run_cactus.sh batch_a
./scripts/run_cactus.sh batch_b
./scripts/run_cactus.sh all
```

运行时间：

运行	运行时间	状态
batch_a	1609.44 s, 约 26.82 min	成功, 无 WARNING
batch_b	1446.77 s, 约 24.11 min	成功, 无 WARNING
all	1828.25 s, 约 30.47 min	成功, 无 WARNING

Clipping summary: 三个运行的每个 genome 均为 `TOTAL=0 bp`，即输入序列没有因染色体分配、裁剪或过滤丢失。

6. GFA summary

图	S 节点	L 边	W 路径	节点总 bp	路径总 bp
A	45124	61399	7	5116345	35000000
B	45130	61280	7	5143857	35000000
ALL	59302	81171	13	5216808	65000000

路径构成

- A 批 GFA: CHM13v2 + HG00438.1/2 + HG01109.1/2 + HG02486.1/2;
- B 批 GFA: CHM13v2 + HG00642.1/2 + HG01884.1/2 + HG02602.1/2;
- ALL GFA: CHM13v2 + A/B 共 12 条样本单倍型。

A/B 样本 W 在 ALL 中的同名 W 长度与碱基序列全部一致。这个结论由 Java 的 `w_base_identity` 和 `s_mosaic_match_bp_pct` 独立验证。

7. Java W/S 重叠度程序

程序目录：

```
results/match/java
```

源文件：

```
results/match/java/WOverlapComparator.java
```

编译和运行：

```
cd /Users/zizibei/Desktop/pwj/minigraph-catus
javac -d results/match/java results/match/java/WOverlapComparator.java

java -Xmx6g -cp results/match/java WOverlapComparator \
  --batchA results/batch_a/batch_a.full.gfa.gz \
  --batchB results/batch_b/batch_b.full.gfa.gz \
  --integrated results/all/all.full.gfa.gz \
  --outdir results/match/output
```

7.1 比较原则

程序不比较节点 ID，因为三次 Cactus 运行的节点 ID 空间不同。比较分为四层：

1. W 层

重建 W 的完整碱基序列，比较长度、正反向、逐碱基 identity 和 coverage。

2. S 边界层

把 W 展开为路径坐标上的 S 区间，计算内部边界的：

- intersection;
- Jaccard;
- precision;
- recall;
- F1;
- 每个单独图边界到最近整合图边界的距离。

3. S 区间层

- `exact_single_match`：单独图一个 S 区间是否恰好等于整合图一个 S 区间；
- `split`：单独图一个 S 节点包含多个整合图 S 边界；
- `merged`：整合图一个 S 节点包含多个单独图 S 边界；
- `s_mosaic_match`：单独图一个 S 区间的序列是否等于整合图同一路径坐标区间的拼接序列。这个指标区别于 1:1 节点匹配。

4. S 序列多重集/集合层

用规范化序列 SHA-256 表示 S 节点的核苷酸内容，忽略节点 ID，计算：

- 路径内 S 序列多重集 Jaccard；
- 单独图 S 序列是否在整合图中存在；
- 全图 S 集合的节点和 bp Jaccard。

7.2 输出文件

```
results/match/output/path_metrics.csv
results/match/output/sample_summary.csv
results/match/output/batch_summary.csv
results/match/output/graph_summary.csv
results/match/output/s_graph_overlap.csv
results/match/output/boundary_distance_histogram.csv
results/match/output/s_segment_correspondence.tsv.gz
results/match/output/summary.json
```

8. 每个样本的 W/S 重合度

样本	单倍型	W identity	S mosaic	S boundary F1	Exact 1:1 S	Split S	Merged S	S multiset Jaccard	S 命中整合图	最近边界均值
HG00438	2	100.00%	100.00%	84.10%	62.43%	36.14%	8.67%	45.42%	62.48%	3.215 bp
HG01109	2	100.00%	100.00%	84.18%	62.52%	36.06%	8.55%	45.51%	62.56%	3.119 bp
HG02486	2	100.00%	100.00%	84.16%	62.62%	35.96%	8.47%	45.63%	62.67%	3.109 bp
HG00642	2	100.00%	100.00%	84.17%	59.32%	39.16%	10.19%	42.19%	59.36%	3.653 bp
HG01884	2	100.00%	100.00%	84.12%	59.35%	39.14%	10.19%	42.23%	59.39%	3.652 bp
HG02602	2	100.00%	100.00%	84.13%	59.68%	38.82%	10.19%	42.56%	59.72%	3.676 bp

每个单倍型的核心指标

分批/样本.单倍型	单独 S 数	整合 S 数	数量比	Boundary F1	Exact 1:1 S bp	Split S bp	Merged S bp	S mosaic bp	S multiset Jaccard
A:HG00438.1	30230	39297	0.769	83.94%	62.37%	36.20%	8.74%	100.00%	45.36%
A:HG00438.2	30521	39528	0.772	84.26%	62.49%	36.09%	8.60%	100.00%	45.48%
A:HG01109.1	30530	39585	0.771	84.16%	62.57%	36.01%	8.49%	100.00%	45.57%
A:HG01109.2	30480	39516	0.771	84.20%	62.46%	36.11%	8.60%	100.00%	45.45%
A:HG02486.1	30364	39417	0.770	84.13%	62.54%	36.04%	8.49%	100.00%	45.54%
A:HG02486.2	30361	39372	0.771	84.18%	62.70%	35.88%	8.45%	100.00%	45.71%
B:HG00642.1	30442	39398	0.773	84.18%	59.34%	39.14%	10.18%	100.00%	42.22%
B:HG00642.2	30427	39396	0.772	84.16%	59.29%	39.19%	10.21%	100.00%	42.17%
B:HG01884.1	30463	39498	0.771	84.06%	59.25%	39.23%	10.24%	100.00%	42.14%
B:HG01884.2	30313	39312	0.771	84.18%	59.45%	39.06%	10.13%	100.00%	42.33%
B:HG02602.1	30231	39164	0.772	84.10%	59.74%	38.76%	10.19%	100.00%	42.63%
B:HG02602.2	30386	39323	0.773	84.16%	59.61%	38.88%	10.20%	100.00%	42.50%

批次汇总

批次	路径	总 bp	W identity	S mosaic	Boundary precision	Boundary recall	Boundary F1	Exact 1:1 S	Split S	Merged S	S multiset Jaccard
A	6	30000000	100.00%	100.00%	96.65%	74.51%	84.15%	62.52%	36.05%	8.56%	45.52%
B	6	30000000	100.00%	100.00%	96.57%	74.55%	84.14%	59.45%	39.04%	10.19%	42.33%

全图 S 节点集合重合

比较	共享 S 节点	A 单独节点	B 单独节点	A bp 命中	B bp 命中	节点 Jaccard	bp Jaccard
A_vs_ALL	12259	16090	20062	62.38%	61.33%	51.31%	44.77%
B_vs_ALL	12103	16125	20062	59.93%	59.25%	50.25%	42.44%

说明：`A bp hit` 表示 A 批单独图 S 节点序列中，能在整合图 S 节点集合里直接找到的部分。它是“节点序列直接命中率”，不是 W 碱基一致率；后者是 100%。

9. 结果解释

9.1 W 层

12 条样本 W：

- 长度完全相同：5,000,000 bp；
- 正链逐碱基一致率：100%；
- 没有发生反向互补替换；
- 因此按参考坐标提取的单倍型序列区间完全一致。

9.2 S 节点切分层

单独图和整合图的节点边界并不完全相同：

- A 批 boundary precision 平均 96.65%，recall 平均 74.51%，F1 平均 84.15%；
- B 批 boundary precision 平均 96.57%，recall 平均 74.55%，F1 平均 84.14%；
- 单独图 S 节点平均长度约为 164 bp，整合图约为 128 bp；
- 单独图一个 S 节点约 36% A 批 bp、39% B 批 bp 会跨多个整合图 S 节点；
- 约 8.6% A 批 bp、10.2% B 批 bp 的整合图 S 节点跨多个单独图 S 节点。

9.3 S 序列内容层


- `s_mosaic_match_bp_pct = 100%`；
- 说明单独图的每个 S 区间，即使对应多个整合图 S 节点，拼接后的序列仍完全一致；
- 因此不存在因节点重新切分造成的序列内容丢失。

9.4 S 节点序列命中和多重集


- A 批 S 节点序列 bp 直接命中整合图：约 62.38%；
- B 批 S 节点序列 bp 直接命中整合图：约 59.93%；
- A/B 与整合图的全图 bp Jaccard：约 44.77% / 42.44%；
- 这类低比例反映的是“节点边界/节点集合不同”，不是 W 序列丢失。

10. Matplotlib 图片


W 序列与 S 切分保留




S 边界 precision / recall / F1




精确 1:1 S 节点、拆分和合并




S 节点序列复用




S 节点数量变化




边界距离分布




全图 S 节点集合重合




图复杂度




多层次指标热图




边界距离 summary



S mosaic identity 与节点复用



面向通俗解释的总览



这张总览图把五个关键指标放在同一坐标中：W sequence 和 S mosaic 均约 100%，而 S boundary F1、Exact 1:1 S、S multiset Jaccard 较低。它直接表达了“DNA 内容一致，但图的节点切分表示不同”这一核心结论。

10.1 如何从整合图中提取 region、样本 W 和 node list

完整中文操作说明见：

```
results/match/region_extraction.md
```

核心链路：

```
GBZ -> XG -> vg chunk(region) -> GFA/VG -> vg snarls -> vg deconstruct
```

区域 GFA 的每个 W-line 提供：

```
sample, haplotype, contig, seq_start, seq_end, node walk
```

因此可以得到每个样本在该 region 下的 node list，并通过 `vg paths -F` 提取对应 W 序列。


11. 数学推导与严格上下界

详细推导见：

```
results/match/math_derivation.md
```

核心严格结论：

- 在 full graph、`--clip 0`、`--filter 0`、无 unassigned 的条件下，A 样本 W 序列在加入 B 后不变；
- S mosaic identity 由 W 序列保持一致直接推出，当前实验中为 100%；
- S 边界 Jaccard 的普遍下界是 0，不能仅靠 Cactus 原理推出 99% 的 S 边界一致；
- S 节点数在 `maxNodeLength=1024` 下有理论范围，但不能给出接近 1 的边界 Jaccard 下界；
- 当前数据中 S 边界 F1 稳定在约 84%，属于经验稳定性，而不是普遍数学必然。



11. 结论与限制

- 若判断标准是“每个样本的 W 序列在共同参考坐标区间上是否一致”，本实验结果为 **100% 一致**。
- 若判断标准是“S 节点边界和 1:1 节点结构是否一致”，本实验结果为 **不是 100%**，平均 boundary F1 约为 84.14%。
- 若判断标准是“单独图的 S 序列内容是否完整保留在整合图路径中”，令 `s_mosaic_match_bp_pct` 作为指标，结果为 **100%**。
- 整合图的 S 节点更密集、更碎，这是联合建图面对更多单倍型时重新切分 node 的结果。

5. 当前数据中 W 序列完全一致，因此 Java 程序不需要外部比对器；若未来 W 序列不完全一致，建议在 Java 中增加 minimap2 调用或先进行图对齐，再进行坐标级 S 比较。
6. 本报告比较的是 Cactus 的 `batch_a`、`batch_b` 与联合 `all`，并未评价你自己的 GFA 合并工具，因为该工具的可执行文件和 CLI 尚未接入。